


UNIVERSIDADE FEDERAL DE MATO GROSSO DO SUL  
FACULDADE DE COMPUTAÇÃO CURSO DE CIÊNCIA DA COMPUTAÇÃO

# Uma Abordagem Matheurística baseada em Large Neighborhood Search para o Problema da Distribuição de Disciplinas

Deivid Reinke Schutz

Campo Grande - MS

23 de Janeiro de 2026



UNIVERSIDADE FEDERAL DE MATO GROSSO DO SUL  
FACULDADE DE COMPUTAÇÃO CURSO DE CIÊNCIA DA COMPUTAÇÃO

# **Uma Abordagem Matheurística baseada em Large Neighborhood Search para o Problema da Distribuição de Disciplinas**

Deivid Reinke Schutz

Trabalho de Conclusão de Curso apresentado  
como exigência para obtenção do grau de Bacha-  
relado em Ciência da Computação da Universi-  
dade Federal de Mato Grosso do Sul – UFMS.

Orientador: Profa. Dr. Edna Ayako Hoshino

Campo Grande - MS  
23 de Janeiro de 2026

# Uma Abordagem Matheurística baseada em Large Neighborhood Search para o Problema da Distribuição de Disciplinas

Trabalho de Conclusão de Curso apresentado como exigência para obtenção do grau de  
Bacharelado em Ciência da Computação da Universidade Federal de Mato Grosso do  
Sul – UFMS.

## **Banca Examinadora:**

---

Profa. Dr. Edna Ayako Hoshino

---

Prof. Dr. Membro da banca 1

---

Prof. Dr. Membro da banca 2

Campo Grande - MS  
23 de Janeiro de 2026

# Agradecimentos

À minha família.

# Resumo

A atribuição de disciplinas a professores em instituições de ensino superior é um problema combinatório recorrente, classificado como NP-difícil por sua relação com o *Generalized Assignment Problem*, cuja complexidade cresce com o número de docentes, disciplinas e restrições operacionais envolvidas, tornando métodos exatos baseados em Programação Linear Inteira (PLI) potencialmente inviáveis em tempo computacional para instâncias de maior porte, ao passo que abordagens puramente heurísticas não oferecem garantias de qualidade. Este trabalho propõe, implementa e avalia uma matheurística baseada em Large Neighborhood Search (LNS) com reotimização por sub-MIP, em um esquema do tipo *fix-and-optimize*, integrada como heurística primal ao solver SCIP 7.0, para o Problema da Distribuição de Disciplinas (PDD), modelado como um programa linear inteiro binário cuja função objetivo maximiza a qualidade da atribuição com base em preferências docentes e compatibilidade de área, sujeito a restrições de cobertura obrigatória de todas as disciplinas, carga horária mínima anual e máxima semestral por professor. A heurística LNS opera como mecanismo de intensificação integrado ao Branch-and-Bound (B&B): a partir de uma solução incumbente, identifica as atribuições ativas, ordena os candidatos segundo uma métrica de versatilidade docente e libera uma fração controlada das variáveis para reotimização em um subproblema auxiliar (sub-MIP) com limite de tempo, incorporando a solução resultante ao solver principal caso represente melhoria. Três parâmetros internos — taxa de destruição, sentido de ordenação dos candidatos e tempo máximo do sub-MIP — foram calibrados por meio de uma abordagem incremental *one-factor-at-a-time*, utilizando 42 instâncias sintéticas com limite de tempo global de 400 segundos por instância, sendo o número de nós restantes na árvore de B&B o critério de desempate decisivo em todas as etapas. A configuração final selecionada — 75% de destruição, ordenação crescente e 200 segundos de sub-MIP — demonstrou que vizinhanças maiores e investimentos temporais mais longos em cada chamada produzem incumbentes de melhor qualidade, acelerando a convergência do B&B por meio de podas mais agressivas. No comparativo final entre quatro abordagens — B&B puro, LNS, heurística construtiva *Greedy Randomized Adaptive Search Procedure* (GRASP) e variante híbrida GRASP|LNS —, a matheurística LNS superou todas as demais em todas as métricas avaliadas: resolveu as 10 instâncias de teste até a otimalidade com gap de 0,00% e nenhum nó remanescente na árvore de busca, em um tempo total de 230 segundos, o que representa uma redução de 69% em relação ao B&B puro (744 segundos) e de 82% em relação ao GRASP (1.314 segundos), ao passo que o B&B puro deixou 64.364 nós pendentes e o GRASP, 36.303. A variante híbrida GRASP|LNS não apresentou ganhos adicionais frente ao LNS isolado, indicando que a matheurística é capaz de gerar incumbentes de qualidade suficiente independentemente de uma solução inicial construtiva dedicada. Os resultados confirmam que a integração de uma matheurística LNS ao B&B constitui uma estratégia eficaz para o PDD, viabilizando a obtenção de soluções ótimas em tempo computacional compatível com os prazos institucionais de planejamento acadêmico.

**Palavras-chave:** Distribuição de Disciplinas. Programação Linear Inteira. Branch-and-Bound. Matheurística. Large Neighborhood Search. Fix-and-Optimize. SCIP.

# Lista de ilustrações

|            |                                                                                                                                                                                                            |    |
|------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Figura 1 – | Número total de nós restantes na árvore de Branch-and-Bound para diferentes taxas de destruição do LNS. A configuração de 75% apresentou o melhor desempenho com 58.921 nós restantes. . . . .             | 22 |
| Figura 2 – | Comparação do número total de nós restantes entre ordenação crescente e decrescente. A ordenação crescente (priorizando professores versáteis) obteve melhor desempenho com 131.997 nós restantes. . .     | 24 |
| Figura 3 – | Impacto do limite de tempo do sub-MIP no número de nós restantes. A configuração de 200s demonstrou o melhor desempenho com 33.539 nós, representando uma redução de 75,3% em relação ao B&B puro. . . . . | 27 |
| Figura 4 – | Tempo total de execução (segundos) para cada configuração. O LNS obteve o menor tempo total (230,05s), representando uma redução de 69,1% em relação ao B&B puro e de 82,5% em relação ao GRASP. . . . .   | 29 |
| Figura 5 – | Gap de otimalidade total (%) para cada configuração. O LNS atingiu gap zero, provando a otimalidade de todas as soluções encontradas. . . . .                                                              | 30 |
| Figura 6 – | Total de nós restantes na árvore de Branch-and-Bound para cada configuração. O LNS alcançou 0 nós restantes, resolvendo todas as instâncias até a otimalidade. . . . .                                     | 31 |

# Lista de tabelas

|           |   |                                                                                                                                                                                                 |    |
|-----------|---|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Tabela 1  | – | Notação do modelo matemático do PDD. . . . .                                                                                                                                                    | 15 |
| Tabela 2  | – | Tempo de execução (segundos) para diferentes taxas de destruição do LNS. Configuração: ordenação crescente, tempo LNS = 30s, limite global = 400s. . . . .                                      | 21 |
| Tabela 3  | – | Gap de otimalidade (%) para diferentes taxas de destruição. Configuração: ordenação crescente, tempo LNS = 30s, limite global = 400s. . . . .                                                   | 21 |
| Tabela 4  | – | Número de nós restantes na árvore de Branch-and-Bound para diferentes taxas de destruição. Configuração: ordenação crescente, tempo LNS = 30s, limite global = 400s. . . . .                    | 22 |
| Tabela 5  | – | Tempo de execução (segundos) comparando ordenação crescente e decrescente. Configuração: 75% de destruição, tempo LNS = 30s, limite global = 400s. . . . .                                      | 23 |
| Tabela 6  | – | Gap de otimalidade (%) comparando ordenação crescente e decrescente. Configuração: 75% de destruição, tempo LNS = 30s, limite global = 400s. . . . .                                            | 23 |
| Tabela 7  | – | Número de nós restantes comparando ordenação crescente e decrescente. Configuração: 75% de destruição, tempo LNS = 30s, limite global = 400s. . . . .                                           | 24 |
| Tabela 8  | – | Tempo de execução (segundos) para diferentes limites de tempo do sub-MIP. Configuração: 75% de destruição, ordenação crescente, limite global = 400s. . . . .                                   | 25 |
| Tabela 9  | – | Gap de otimalidade (%) para diferentes limites de tempo do sub-MIP. Configuração: 75% de destruição, ordenação crescente, limite global = 400s. . . . .                                         | 26 |
| Tabela 10 | – | Número de nós restantes para diferentes limites de tempo do sub-MIP. Configuração: 75% de destruição, ordenação crescente, limite global = 400s. . . . .                                        | 26 |
| Tabela 11 | – | Configuração final da heurística LNS selecionada pela análise incremental. . . . .                                                                                                              | 27 |
| Tabela 12 | – | Tempo de execução (segundos) comparando B&B puro, LNS, GRASP e GRASP LNS. Configuração LNS: 75% destruição, crescente, 200s. Configuração GRASP: max_iter=1, alpha=0.8, local_search=0. . . . . | 28 |

|           |   |                                                                                                                                                                                            |    |
|-----------|---|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Tabela 13 | – | Gap de otimalidade (%) comparando B&B puro, LNS, GRASP e GRASP LNS. Configuração LNS: 75% destruição, crescente, 200s. Configuração GRASP: max_iter=1, alpha=0.8, local_search=0. . . . .  | 29 |
| Tabela 14 | – | Número de nós restantes comparando B&B puro, LNS, GRASP e GRASP LNS. Configuração LNS: 75% destruição, crescente, 200s. Configuração GRASP: max_iter=1, alpha=0.8, local_search=0. . . . . | 30 |
| Tabela 15 | – | Resumo comparativo das quatro configurações avaliadas. . . . .                                                                                                                             | 31 |



# Sumário

|          |                                                             |           |
|----------|-------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introdução</b>                                           | <b>8</b>  |
| <b>2</b> | <b>Fundamentação Teórica</b>                                | <b>10</b> |
| 2.1      | Otimização Combinatória e Programação Linear Inteira (PLI)  | 10        |
| 2.2      | O Método Branch-and-Bound e Relaxação Linear                | 10        |
| 2.3      | Heurísticas e Metaheurísticas                               | 11        |
| 2.3.1    | Greedy Randomized Adaptive Search Procedure (GRASP)         | 11        |
| 2.4      | Matheurísticas                                              | 12        |
| 2.4.1    | Large Neighborhood Search (LNS) e Reotimização por Sub-MIP  | 12        |
| <b>3</b> | <b>O Problema da Distribuição de Disciplinas (PDD)</b>      | <b>14</b> |
| 3.1      | Definição do Problema                                       | 14        |
| 3.2      | Modelo Matemático Exato                                     | 14        |
| 3.3      | Matheurística LNS Proposta                                  | 16        |
| 3.3.1    | Definição de Candidatos e Ordenação                         | 17        |
| 3.3.2    | Destruição (Destroy)                                        | 17        |
| 3.3.3    | Reparo (Repair) via Sub-MIP                                 | 17        |
| 3.3.4    | Integração com o SCIP                                       | 18        |
| <b>4</b> | <b>Resultados e Análise Computacional</b>                   | <b>19</b> |
| 4.1      | Instâncias e Ambiente de Testes                             | 19        |
| 4.2      | Análise Interna das Configurações da LNS                    | 20        |
| 4.2.1    | Impacto da Taxa de Destruição (10%, 25%, 50% e 75%)         | 20        |
| 4.2.2    | Impacto do Sentido de Ordenação (Crescente vs. Decrescente) | 22        |
| 4.2.3    | Impacto do Tempo Máximo do LNS (10s, 50s, 100s e 200s)      | 25        |
| 4.2.4    | Resumo da Configuração Seleccionada                         | 27        |
| 4.3      | Comparativo de Desempenho: LNS, GRASP e Modelo Exato        | 27        |
| 4.3.1    | Análise do Tempo de Execução                                | 28        |
| 4.3.2    | Análise do Gap de Otimalidade                               | 28        |
| 4.3.3    | Análise dos Nós Restantes                                   | 30        |
| 4.3.4    | Discussão dos Resultados                                    | 30        |
| <b>5</b> | <b>Conclusão</b>                                            | <b>33</b> |
| 5.1      | Limitações                                                  | 33        |
| 5.2      | Trabalhos Futuros                                           | 34        |

# 1 Introdução

A gestão acadêmica semestral em instituições de ensino superior envolve um conjunto amplo de decisões interdependentes, entre as quais a atribuição de disciplinas a professores ocupa papel central. Trata-se de um problema recorrente, sensível ao contexto e de natureza combinatória: a cada período, mudanças no quadro docente, na oferta de disciplinas ou nas regras de carga horária podem alterar significativamente o espaço de soluções viáveis. Na literatura de pesquisa operacional, esse tipo de problema é estudado há décadas sob denominações como *class-faculty assignment* e *course timetabling* (????), o que reflete tanto a sua ubiquidade institucional quanto a sua complexidade computacional.

A abordagem padrão para modelar problemas de alocação docente é a Programação Linear Inteira (PLI), em que decisões binárias representam atribuições entre professores e disciplinas, e a função objetivo quantifica a qualidade da alocação por meio de pesos que combinam preferência e compatibilidade de área (??). Restrições lineares codificam requisitos operacionais, como carga horária mínima anual e máxima semestral por professor e cobertura obrigatória de todas as disciplinas. No contexto de atribuição de docentes com preferências, trabalhos como ??) e ??) demonstram a eficácia dessa formulação para capturar exigências institucionais de forma sistemática. Modelos de PLI são resolvidos por métodos exatos como o Branch-and-Bound (B&B), implementado em solvers modernos como o *Solving Constraint Integer Programs* (SCIP) (??), que utiliza relaxações lineares como limites para guiar a enumeração e podar regiões improdutivas da árvore de busca (??).

Apesar da expressividade dos modelos exatos, instâncias de maior porte ou com restrições mais detalhadas podem dificultar a obtenção da prova de otimalidade dentro de limites de tempo práticos: o B&B pode explorar um número exponencial de nós sem convergir, devolvendo soluções com gap significativo. No contexto específico do Problema da Distribuição de Disciplinas (PDD), ??) investigou uma abordagem exata via PLI, enquanto ??) desenvolveu uma heurística construtiva baseada em *Greedy Randomized Adaptive Search Procedure* (GRASP). O presente trabalho avança sobre essas contribuições ao propor uma matheurística de melhoria baseada em Large Neighborhood Search (LNS), combinando a qualidade de soluções iniciais obtidas por GRASP com uma etapa de refinamento via subproblema de Programação Inteira Mista (sub-MIP). A integração de matheurísticas baseadas em programação matemática — em particular, a LNS em um esquema do tipo *fix-and-optimize* como heurística primal do SCIP — permanecia inexplorada para o PDD, configurando a lacuna metodológica que motiva o presente trabalho.

Esta monografia propõe, implementa e avalia uma matheurística baseada em LNS integrada ao solver SCIP para o PDD. O problema é modelado como um PLI binário e resolvido por B&B, enquanto a LNS atua como mecanismo de intensificação: a partir de uma solução incumbente, uma fração controlada das atribuições é liberada para reotimização em um subproblema auxiliar (sub-MIP) com limite de tempo, e, caso uma solução de melhor qualidade seja encontrada, ela é incorporada ao solver principal como nova incumbente (??). Três parâmetros internos são analisados sistematicamente — taxa de destruição, sentido de ordenação dos candidatos e tempo máximo do sub-MIP — por meio de uma abordagem *one-factor-at-a-time*. O desempenho da LNS é então comparado com três estratégias alternativas: o B&B puro, a heurística GRASP (??) e uma variante híbrida GRASP|LNS, na qual a LNS é aplicada como etapa de melhoria a partir de soluções construídas pelo GRASP (????).

A distribuição de disciplinas é realizada a cada semestre e está sujeita a prazos institucionais que demandam respostas rápidas, mesmo quando a prova de otimalidade não é exigida. Nesse cenário, a capacidade de gerar incumbentes de alta qualidade em estágios iniciais do B&B tem impacto direto na eficiência da busca: soluções melhores permitem podas mais agressivas da árvore, acelerando a convergência (??). Matheurísticas do tipo *fix-and-optimize* exploram precisamente essa propriedade ao resolver, repetidamente, versões restritas do problema original com estrutura preservada da incumbente corrente.

Apartir desta introdução, no Capítulo 2 é apresentada a fundamentação teórica, cobrindo conceitos de otimização inteira, heurísticas e matheurísticas relevantes ao estudo. O Capítulo 3 define o PDD formalmente e descreve tanto o modelo matemático exato quanto a matheurística LNS proposta. O Capítulo 4 apresenta os resultados experimentais e a análise computacional, incluindo a calibração dos parâmetros internos da LNS e as comparações de desempenho entre as abordagens. Por fim, o Capítulo 5 conclui o trabalho e discute limitações e possibilidades de trabalhos futuros.

## 2 Fundamentação Teórica

### 2.1 Otimização Combinatória e Programação Linear Inteira (PLI)

Problemas de alocação em ambientes acadêmicos podem ser formulados como problemas de otimização combinatória, nos quais se busca selecionar uma atribuição que maximize uma medida de qualidade (por exemplo, preferências) e, ao mesmo tempo, respeite restrições operacionais (carga horária, conflitos e requisitos mínimos). Na literatura, problemas próximos incluem o *class-faculty assignment* e variantes de alocação docente com preferências (?????), bem como estudos em *course timetabling* (????).

Uma forma padrão de modelar tais problemas é por Programação Linear Inteira (PLI), em que variáveis de decisão (frequentemente binárias) representam escolhas discretas, e a função objetivo quantifica a qualidade da solução. De modo geral, um modelo pode ser escrito conforme a Equação (2.1):

$$\max \sum_{p \in P} \sum_{c \in C} w_{p,c} x_{p,c} \quad \text{sujeito a restrições lineares e } x_{p,c} \in \{0, 1\}, \quad (2.1)$$

em que  $x_{p,c} = 1$  indica que o professor  $p$  é designado à disciplina  $c$ , e  $w_{p,c}$  representa o peso/preferência. A PLI permite representar restrições de compatibilidade e limites de capacidade de forma explícita, mantendo uma interpretação direta do modelo (????).

### 2.2 O Método Branch-and-Bound e Relaxação Linear

Modelos de PLI são, em geral, NP-difíceis, de modo que solucionadores utilizam métodos exatos baseados em limites e enumeração inteligente. Um componente central é a relaxação linear, obtida ao substituir a integralidade por  $0 \leq x \leq 1$ , produzindo um problema de Programação Linear (PL) que fornece um limite para a solução inteira ótima (????).

O Branch-and-Bound (B&B) explora uma árvore de subproblemas: a cada nó, resolve-se uma relaxação para obter um limite e, quando necessário, ramifica-se em subproblemas impondo decisões de integralidade (por exemplo,  $x_{p,c} = 0$  ou  $x_{p,c} = 1$ ). Nós cujos limites não superam a melhor solução inteira conhecida podem ser podados, reduzindo a busca (??). Na prática, solucionadores modernos integram B&B com técnicas adicionais; neste trabalho, a resolução exata é realizada com o SCIP (??).

## 2.3 Heurísticas e Metaheurísticas

Embora métodos exatos forneçam garantias de otimalidade, instâncias reais podem apresentar grande dimensão e múltiplas restrições, tornando necessário recorrer a estratégias aproximadas. Heurísticas constroem boas soluções em tempo reduzido, enquanto metaheurísticas organizam mecanismos de exploração e intensificação para escapar de ótimos locais e melhorar soluções iterativamente.

Para problemas de alocação docente, há abordagens heurísticas e metaheurísticas que exploram diferentes representações e movimentos de vizinhança, como algoritmos genéticos (??) e heurísticas voltadas a contextos específicos de atribuição docente — como a atribuição de assistentes de ensino a sessões de laboratório (??) e a incorporação de competências curriculares na alocação de professores (??). Esse corpo de técnicas é especialmente útil quando se deseja produzir soluções de boa qualidade sob limites de tempo, ou quando o modelo exato é utilizado como referência/validação.

Uma distinção conceitual importante separa heurísticas, metaheurísticas e matheurísticas (????). Heurísticas são procedimentos específicos ao problema que exploram sua estrutura para construir ou melhorar soluções de forma eficiente, sem garantia de otimalidade; exemplos clássicos incluem heurísticas gulosas construtivas e buscas locais simples por troca de pares. Metaheurísticas são estratégias de alto nível, independentes de domínio, que orquestram mecanismos de intensificação (exploração em torno de soluções promissoras) e diversificação (exploração de regiões ainda não visitadas), visando escapar de ótimos locais (??). Tanto heurísticas quanto metaheurísticas operam diretamente sobre representações de soluções, sem interagir com nenhum modelo matemático formal. Matheurísticas, categoria distinta, embutem um solver de otimização (como um solver de MIP) como operador de melhoria ou construção, aproveitando simultaneamente a estrutura matemática do modelo — em particular, limites de qualidade e garantias de viabilidade — e a flexibilidade das estratégias de busca (????). Essa combinação é especialmente vantajosa quando o problema admite formulação exata, mas as instâncias práticas excedem a capacidade dos solvers em tempo razoável.

### 2.3.1 Greedy Randomized Adaptive Search Procedure (GRASP)

O GRASP é uma metaheurística em duas fases: (i) uma construção gulosa aleatorizada, que produz uma solução inicial por escolhas guiadas por um critério de qualidade com componente probabilística; e (ii) uma busca local, que tenta melhorar a solução por movimentos em uma vizinhança definida. A aleatoriedade permite amostrar diferentes regiões do espaço de soluções, enquanto a busca local promove intensificação.

No contexto do Problema da Distribuição de Disciplinas (PDD), uma estratégia GRASP é um caminho natural por combinar regras gulosas (por exemplo, priorizar pares

professor–disciplina com maior peso) com fases de melhoria que reatribuem disciplinas para reduzir violações e aumentar a qualidade (??).

## 2.4 Matheurísticas

Matheurísticas combinam programação matemática com componentes heurísticos/metaheurísticos, buscando aproveitar simultaneamente a força de modelagem e os limites fornecidos por modelos exatos, e a flexibilidade de estratégias de busca em grandes espaços combinatórios (??????). Em geral, a ideia é usar submodelos (ou modelos restritos) como operadores de melhoria, resolver subproblemas por Programação Inteira Mista (MIP)/CPLEX/SCIP, ou ainda usar informações do solucionador (limites, incumbentes, cortes) para orientar a busca.

Em problemas do tipo mochila e variantes, como o Problema da Mochila com Conjuntos de Penalidades (??), há linhas de trabalho que empregam resoluções exatas em subestruturas, gerando melhorias sistemáticas em torno de incumbentes (????). Essa mesma filosofia se estende ao PDD: parte-se de um modelo de PLI e explora-se uma vizinhança definida sobre variáveis binárias, reotimizando subproblemas com tempo controlado.

Aplicações reais de matheurísticas LNS foram reportadas em problemas estruturalmente próximos ao PDD. Em roteamento de veículos, ??) propuseram uma Large Neighborhood Search Adaptativa que destrói e repara soluções por meio de múltiplos operadores selecionados por pesos adaptativos, obtendo resultados de estado da arte no *Pickup and Delivery Problem with Time Windows* — um problema de alocação e sequenciamento com restrições de capacidade análogas às de carga horária. Em escala de pessoal (*workforce scheduling*), estratégias de reotimização por MIP com parte das decisões da incumbente fixadas são amplamente empregadas para resolver instâncias industriais de alocação de enfermeiros e funcionários a turnos (??), domínio cuja estrutura — atribuição de recursos humanos respeitando restrições de disponibilidade e demanda mínima — guarda simetria direta com a distribuição de disciplinas docentes. Esses resultados consolidam a LNS com reotimização por sub-MIP como uma estratégia robusta e bem motivada para o PDD.

### 2.4.1 Large Neighborhood Search (LNS) e Reotimização por Sub-MIP

O Large Neighborhood Search (LNS) alterna etapas de *destroy* e *repair*: uma porção da solução corrente é liberada (ou removida) e, em seguida, o problema restrito é resolvido para reparar e potencialmente melhorar a solução. A principal vantagem é permitir movimentos de grande alcance, mantendo a viabilidade por meio de um procedi-

mento de reparo eficaz (????). Uma implementação prática e amplamente adotada é usar um solucionador MIP na etapa de reparo, o que transforma o LNS em uma matheurística.

Na literatura, diferentes esquemas de reotimização podem ser combinados ao LNS. Em procedimentos construtivos do tipo *relax-and-fix* ou *fix-and-relax*, parte das variáveis é fixada, parte permanece inteira e outra parte tem a integralidade relaxada, produzindo uma sequência de subproblemas usados para construir soluções. Já em abordagens de melhoria do tipo *fix-and-optimize*, parte das variáveis da incumbente é fixada e um subconjunto permanece livre e inteiro para reotimização, mantendo-se a estrutura do modelo original por meio de limites ou restrições adicionais (??). Para o PDD, o mecanismo adotado neste trabalho se alinha a essa segunda classe: a vizinhança é definida a partir da incumbente, a maior parte das variáveis binárias é mantida fixa e um subconjunto de atribuições é liberado para um sub-MIP temporariamente restrito.

Esse esquema de fixação parcial de variáveis pode ser visto como uma forma estruturada de definir vizinhanças: fixa-se a maior parte das decisões da incumbente e libera-se um subconjunto selecionado para reotimização, normalmente sob um limite de tempo. Como as variáveis liberadas permanecem binárias, o reparo é efetuado por um sub-MIP que preserva as restrições do modelo original e busca recombinar decisões de modo consistente. Assim, o método proposto neste trabalho utiliza o SCIP (??) como motor de reotimização em vizinhanças geradas a partir de uma solução incumbente.

Por fim, este trabalho se insere na linha de abordagens para o PDD que exploram tanto modelos exatos quanto estratégias de melhoria, dialogando com trabalhos recentes no problema (??) e com a motivação geral de matheurísticas de melhoria para problemas combinatórios de grande porte (??).

## 3 O Problema da Distribuição de Disciplinas (PDD)

### 3.1 Definição do Problema

O Problema da Distribuição de Disciplinas (PDD) consiste em atribuir professores a disciplinas de modo a respeitar restrições operacionais (carga horária mínima anual e máximas por semestre para cada professor, cobertura obrigatória de todas as disciplinas) e, simultaneamente, maximizar a qualidade da alocação. A qualidade de cada atribuição é mensurada por um peso que combina a preferência do professor pela disciplina e a compatibilidade entre a área de atuação do professor e a área da disciplina. Quando um professor é designado a uma disciplina fora de suas áreas de especialização, o modelo aplica uma penalidade (`area_penalty`), resultando em um coeficiente negativo na função objetivo.

Formalmente, temos um conjunto de  $P$  professores e um conjunto de  $C$  disciplinas. Cada disciplina  $j \in C$  possui uma carga horária associada  $ch_j$  (em horas/aula ou créditos) e deve ser atribuída a exatamente um professor. Cada professor  $i \in P$  possui uma carga horária mínima anual  $\min_i$  e cargas horárias máximas  $\max_{i,1}$  e  $\max_{i,2}$  para o primeiro e segundo semestres, respectivamente. O problema é NP-difícil. O PDD pode ser visto como um caso especial do *Generalized Assignment Problem* (GAP), no qual recursos (professores) devem ser atribuídos a tarefas (disciplinas) respeitando restrições de capacidade individuais (??). A NP-dificuldade do GAP é bem estabelecida: o problema contém o Problema da Mochila como caso particular, cujo caráter NP-difícil no sentido fraco é demonstrado em ??). Adicionalmente, problemas de escalonamento de aulas — variantes estreitamente relacionadas ao PDD — foram demonstrados NP-completos por ??) por meio de redução a partir do problema de coloração de grafos. No contexto do PDD especificamente, ??) observa que instâncias de médio porte já demandam tempo computacional expressivo para o Branch-and-Bound puro, evidenciando na prática o comportamento esperado de um problema NP-difícil. Esses resultados justificam a adoção de abordagens heurísticas e matheurísticas, onde a modelagem como Programação Linear Inteira possibilita o uso de solvers exatos de forma integrada à estratégia de busca.

### 3.2 Modelo Matemático Exato

O PDD é formulado como um programa linear inteiro binário, instanciando a estrutura geral de PLI apresentada na Equação (2.1). Os elementos do modelo são or-



ganizados em três categorias — conjuntos e índices, parâmetros e variável de decisão — todos reunidos na Tabela 1.

Os **conjuntos**  $P = \{1, \dots, |P|\}$  e  $C = \{1, \dots, |C|\}$  representam, respectivamente, o conjunto de professores (indexado por  $i$ ) e o conjunto de disciplinas (indexado por  $j$ ). O conjunto de disciplinas é ainda particionado em  $C_1 \subseteq C$  (disciplinas ofertadas no primeiro semestre) e  $C_2 \subseteq C$  (disciplinas ofertadas no segundo semestre), permitindo tratar separadamente as restrições de carga horária de cada período letivo.

Os **parâmetros** do modelo são:  $w_{i,j}$ , o peso associado à atribuição do professor  $i$  à disciplina  $j$ , que assume o valor da preferência declarada quando o professor possui competência na área da disciplina, ou  $w_{i,j} = -\text{area\_penalty} < 0$  quando a disciplina está fora de suas áreas de especialização, penalizando alocações incompatíveis;  $ch_j$ , a carga horária em créditos da disciplina  $j$ ;  $\min_i$ , a carga horária mínima anual obrigatória do professor  $i$ ; e  $\max_{i,1}$  e  $\max_{i,2}$ , as cargas horárias máximas permitidas para o professor  $i$  no primeiro e no segundo semestres, respectivamente.

A **variável de decisão**  $x_{i,j} \in \{0, 1\}$  é binária: assume valor 1 se o professor  $i$  é designado à disciplina  $j$ , e 0 caso contrário.

Tabela 1 – Notação do modelo matemático do PDD.

| Símbolo                    | Descrição                                                                                                                                                                                                  |
|----------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <i>Conjuntos e Índices</i> |                                                                                                                                                                                                            |
| $P = \{1, \dots,  P \}$    | Conjunto de professores; $i \in P$ denota um professor genérico                                                                                                                                            |
| $C = \{1, \dots,  C \}$    | Conjunto de disciplinas; $j \in C$ denota uma disciplina genérica                                                                                                                                          |
| $C_1 \subseteq C$          | Subconjunto de disciplinas do primeiro semestre                                                                                                                                                            |
| $C_2 \subseteq C$          | Subconjunto de disciplinas do segundo semestre                                                                                                                                                             |
| <i>Parâmetros</i>          |                                                                                                                                                                                                            |
| $w_{i,j}$                  | Peso da atribuição do professor $i$ à disciplina $j$ : assume o valor da preferência declarada se o professor tem competência na área da disciplina; caso contrário, $w_{i,j} = -\text{area\_penalty} < 0$ |
| $ch_j$                     | Carga horária (créditos) da disciplina $j$                                                                                                                                                                 |
| $\min_i$                   | Carga horária mínima anual do professor $i$                                                                                                                                                                |
| $\max_{i,1}$               | Carga horária máxima do professor $i$ no primeiro semestre                                                                                                                                                 |
| $\max_{i,2}$               | Carga horária máxima do professor $i$ no segundo semestre                                                                                                                                                  |
| <i>Variável de Decisão</i> |                                                                                                                                                                                                            |
| $x_{i,j} \in \{0, 1\}$     | 1 se o professor $i$ é designado à disciplina $j$ ; 0 caso contrário                                                                                                                                       |

O modelo completo do PDD é apresentado no Programa (3.1):

$$\max Z = \sum_{i \in P} \sum_{j \in C} w_{i,j} x_{i,j} \quad (3.1a)$$

sujeito a:

$$\sum_{i \in P} x_{i,j} = 1, \quad \forall j \in C, \quad (3.1b)$$

$$\sum_{j \in C} ch_j x_{i,j} \geq \min_i, \quad \forall i \in P, \quad (3.1c)$$

$$\sum_{j \in C_1} ch_j x_{i,j} \leq \max_{i,1}, \quad \forall i \in P, \quad (3.1d)$$

$$\sum_{j \in C_2} ch_j x_{i,j} \leq \max_{i,2}, \quad \forall i \in P, \quad (3.1e)$$

$$x_{i,j} \in \{0, 1\}, \quad \forall i \in P, j \in C. \quad (3.1f)$$

A função objetivo (3.1a) maximiza a soma ponderada de todas as atribuições realizadas. Quando o professor possui competência na área da disciplina, o coeficiente  $w_{i,j}$  é positivo e reflete a preferência declarada, contribuindo para aumentar a qualidade da solução. Quando a atribuição ocorre fora da área de especialização,  $w_{i,j} = -\text{area\_penalty}$  é negativo, penalizando explicitamente alocações incompatíveis e desincentivando sua ocorrência na solução final.

A restrição (3.1b) é a restrição de cobertura: garante que cada disciplina  $j$  seja atribuída a exatamente um professor, assegurando que nenhuma disciplina fique sem docente responsável. A restrição (3.1c) impõe que a soma das cargas horárias das disciplinas atribuídas ao professor  $i$  ao longo do ano seja pelo menos igual à sua carga mínima anual  $\min_i$ , respeitando obrigações contratuais. As restrições (3.1d) e (3.1e) estabelecem limites superiores para a carga de cada professor em cada semestre, evitando sobrecarga em um único período letivo. Por fim, o domínio (3.1f) restringe as variáveis ao conjunto binário  $\{0, 1\}$ , garantindo que cada par professor–disciplina seja ou inteiramente atribuído ou não atribuído.

### 3.3 Matheurística LNS Proposta

A matheurística desenvolvida neste trabalho baseia-se no Large Neighborhood Search (LNS) com reotimização por sub-MIP, em um esquema de fixação parcial de variáveis do tipo *fix-and-optimize*. A cada iteração, a heurística parte de uma solução incumbente  $\bar{x}$  e define uma vizinhança ao fixar a maior parte das variáveis binárias e liberar um subconjunto controlado de atribuições para reotimização. A estratégia é implementada no arquivo `heur_lns.c` e integra-se ao framework de heurísticas primais do SCIP.

### 3.3.1 Definição de Candidatos e Ordenação

A partir da solução incumbente  $\bar{x}$ , o algoritmo identifica todas as atribuições ativas (i.e.,  $\bar{x}_{i,j} = 1$ ), formando um conjunto de candidatos. Cada candidato corresponde a um par (professor, disciplina) e possui associado o valor `avgPreferenceWeight` do professor, uma métrica calculada conforme a Equação (3.2):

$$\text{avgPreferenceWeight}_i = \frac{\sum_{j \in J_i} w_{i,j}}{|J_i|} + \frac{|C|}{|J_i|}, \quad (3.2)$$

em que  $J_i$  é o conjunto de disciplinas para as quais o professor  $i$  declarou preferência no arquivo de entrada, e  $|C|$  é o número total de disciplinas. O primeiro termo representa a média aritmética dos pesos de preferência, enquanto o segundo termo ( $|C|/|J_i|$ ) introduz um bônus inversamente proporcional ao grau de versatilidade do professor: professores mais especializados (com menos preferências declaradas) recebem valores maiores, indicando maior prioridade para reotimização devido às suas restrições de alocação.

O conjunto de candidatos é ordenado segundo o parâmetro `lns_order`:

- **"decrecente"** (padrão): candidatos com maior `avgPreferenceWeight` aparecem primeiro, priorizando professores mais especializados (menor número de preferências). Estes professores possuem menos opções alternativas de atribuição, sendo candidatos naturais para reotimização;
- **"crescente"**: ordena em ordem ascendente, priorizando professores mais versáteis (maior número de preferências). Esta estratégia busca explorar a flexibilidade de realocação dos professores generalistas.

### 3.3.2 Destruição (Destroy)

Após a ordenação, o algoritmo seleciona os primeiros  $\lfloor nCands \times lns\_perc \rfloor$  candidatos, onde `lns_perc`  $\in (0, 1)$  é a taxa de destruição configurada pelo usuário. Para cada candidato selecionado, a variável  $x_{i,j}$  correspondente é liberada (i.e., seu valor é desfixado), removendo a atribuição da solução incumbente. As demais variáveis permanecem fixadas nos valores da incumbente.

### 3.3.3 Reparo (Repair) via Sub-MIP

Com o subconjunto de variáveis liberado, o algoritmo resolve um sub-MIP no SCIP auxiliar (mantido em memória pela estrutura `heurdata->subscip`). O sub-MIP possui:

- Todas as restrições do problema original;
- Todas as variáveis binárias do modelo original, com limites ajustados conforme o vetor `fixed[]`;

- Limite de tempo configurado pelo parâmetro `lns_time`;
- Limite de função objetivo (`objlimit`) ajustado para parar assim que uma solução melhor que a incumbente for encontrada.

A resolução do sub-MIP busca reatribuir as disciplinas liberadas de modo a melhorar a função objetivo, respeitando todas as restrições de carga horária e cobertura. Se uma solução melhor é encontrada, ela é transferida para o SCIP principal e passa a ser a nova incumbente.

### 3.3.4 Integração com o SCIP

A heurística LNS é registrada como uma heurística primal do SCIP com prioridade e frequência configuráveis. A cada chamada, a heurística:

1. Verifica se existe uma solução incumbente viável;
2. Extrai os candidatos ativos e ordena conforme `lns_order`;
3. Libera uma fração `lns_perc` das atribuições;
4. Resolve o sub-MIP com limite de tempo `lns_time`;
5. Caso o sub-MIP retorne uma solução de melhor qualidade, adiciona a nova solução ao pool do SCIP principal.

A abordagem permite explorar vizinhanças de tamanho controlado, equilibrando a intensificação (ao focar em atribuições específicas) e a diversificação (ao permitir reatribuições significativas). Os parâmetros `lns_perc`, `lns_order` e `lns_time` oferecem controle sobre o trade-off entre qualidade da solução e tempo computacional, sendo objeto de análise experimental detalhada no próximo capítulo.

## 4 Resultados e Análise Computacional

Este capítulo apresenta os experimentos computacionais realizados para calibrar e avaliar a heurística LNS proposta. Inicialmente, a Seção 4.1 descreve as instâncias de teste, o ambiente computacional e a metodologia de calibração adotada. Em seguida, a Seção 4.2 detalha a análise incremental dos três parâmetros da LNS — taxa de destruição, sentido de ordenação dos candidatos e tempo máximo do sub-MIP —, conduzida conforme a abordagem *one-factor-at-a-time*. Por fim, a Seção 4.3 apresenta o comparativo de desempenho entre a configuração selecionada da LNS, o B&B puro, a heurística GRASP e a variante híbrida GRASP|LNS, avaliando tempo de execução, gap de otimalidade e número de nós restantes na árvore de busca.

### 4.1 Instâncias e Ambiente de Testes

Os experimentos computacionais foram conduzidos utilizando um conjunto de 42 instâncias de teste geradas sinteticamente, abrangendo diferentes cenários do Problema da Distribuição de Disciplinas (PDD). As instâncias variam em tamanho (62 a 214 disciplinas), número de professores (22 a 69), complexidade das restrições de carga horária e distribuição de preferências entre áreas de conhecimento.

Para cada experimento, foram selecionadas aleatoriamente 10 instâncias dentre as 42 disponíveis, garantindo representatividade estatística e mantendo o tempo total de experimentação viável. As mesmas instâncias foram utilizadas em todas as configurações testadas de um mesmo parâmetro, assegurando comparabilidade direta dos resultados.

Todas as execuções foram realizadas com limite de tempo global de 400 segundos por instância, em uma máquina equipada com processador AMD Ryzen 5 5600G, 64 GB de memória RAM e sistema operacional Arch Linux. O solver utilizado foi o SCIP 7.0 (??), integrado com as heurísticas LNS e GRASP desenvolvidas neste trabalho. A calibração dos parâmetros da heurística LNS foi conduzida de forma incremental, conforme a abordagem *one-factor-at-a-time* (OFAT) (??): primeiro determinou-se a melhor taxa de destruição, em seguida o melhor sentido de ordenação e, finalmente, o melhor limite de tempo para o sub-MIP. Essa estratégia ajusta um parâmetro por vez, mantendo os demais fixados, o que permite isolar o efeito individual de cada fator e identificar a configuração mais adequada de forma sistemática. A escolha pelo OFAT foi motivada principalmente pelo custo computacional de uma calibração exaustiva: um projeto fatorial completo sobre os três parâmetros ( $4$  níveis de taxa de destruição  $\times 2$  sentidos de ordenação  $\times 4$  níveis de tempo do sub-MIP =  $32$  combinações), com 10 instâncias e limite de 400 segundos cada, demandaria até  $32 \times 10 \times 400 = 128.000$  segundos ( $\approx 35,6$  horas) de execução, contra

$10 \times 10 \times 400 = 40.000$  segundos ( $\approx 11,1$  horas) da abordagem OFAT — uma redução de aproximadamente 69% no esforço experimental. Reconhece-se que o OFAT não captura possíveis interações entre parâmetros, limitação discutida na Seção de conclusões. Contudo, os três parâmetros da LNS governam aspectos distintos e relativamente independentes do algoritmo — o tamanho da vizinhança (`lns_perc`), a estratégia de seleção de candidatos (`lns_order`) e o orçamento computacional por chamada (`lns_time`) —, o que reduz a probabilidade de interações fortes e torna a abordagem adequada para este contexto.

Para a seleção do melhor valor de cada parâmetro, adotou-se a seguinte hierarquia de critérios de desempate: (i) tempo de execução, (ii) gap de otimalidade e (iii) número de nós restantes na árvore de Branch-and-Bound (*nodes left*). Quando os critérios de maior prioridade apresentaram empate entre as configurações, o critério subsequente foi utilizado como desempate.

## 4.2 Análise Interna das Configurações da LNS

### 4.2.1 Impacto da Taxa de Destruição (10%, 25%, 50% e 75%)

A primeira análise experimental investigou o impacto da taxa de destruição (`lns_perc`) na qualidade das soluções e no desempenho computacional. Foram testadas quatro configurações: 10%, 25%, 50% e 75% de destruição, mantendo fixos o tempo máximo do LNS (30s por chamada), a ordenação (crescente) e o tempo total de execução (400s).

**Tempo de Execução.** A Tabela 2 apresenta os tempos de execução para as 10 instâncias selecionadas. A configuração de B&B puro (sem LNS) obteve o menor tempo total, com **623 segundos**, contra 753 segundos da melhor configuração LNS (75%). Esse resultado é esperado, pois o *overhead* introduzido pelas chamadas ao sub-MIP do LNS aumenta o tempo total, sobretudo em instâncias que já são resolvidas de forma ótima pelo Branch-and-Bound puro. Nove das dez instâncias foram resolvidas até a otimalidade por todas as configurações, e apenas a instância `input7` atingiu o limite de tempo. Embora o B&B puro tenha sido claramente superior, as diferenças entre as quatro configurações LNS foram pequenas (753s a 756s de tempo total), não sendo suficientes para justificar a escolha de uma configuração em detrimento das demais.

**Gap de Otimalidade.** Em termos de gap, todas as configurações — incluindo o B&B puro — apresentaram desempenho equivalente (0,60% de gap total), com apenas a instância `input7` permanecendo sem solução ótima comprovada (ver Tabela 3). Esse empate impediu o uso do gap como critério de seleção.

**Nós Restantes (*Nodes Left*).** Uma vez que o tempo de execução não apresentou diferenças significativas entre as configurações LNS e o gap resultou em empate absoluto,

Tabela 2 – Tempo de execução (segundos) para diferentes taxas de destruição do LNS. Configuração: ordenação crescente, tempo LNS = 30s, limite global = 400s.

| Instância    | Disciplinas | Profs | B&B        | 10%    | 25%    | 50%    | 75%    | Melhor         |
|--------------|-------------|-------|------------|--------|--------|--------|--------|----------------|
| input2       | 79          | 24    | 4,04       | 17,07  | 17,66  | 16,98  | 17,04  | B&B            |
| input5       | 84          | 29    | 113,03     | 145,27 | 145,04 | 145,71 | 143,63 | B&B            |
| input6       | 113         | 31    | 1,07       | 2,47   | 2,40   | 2,33   | 2,22   | B&B            |
| input7       | 99          | 28    | 400,02     | 400,02 | 400,02 | 400,02 | 400,02 | Empate         |
| input9       | 133         | 41    | 17,06      | 72,52  | 72,33  | 72,57  | 73,48  | B&B            |
| input13      | 125         | 39    | 29,13      | 60,21  | 59,56  | 59,04  | 59,43  | B&B            |
| input19      | 114         | 39    | 2,11       | 1,39   | 1,44   | 1,42   | 1,47   | LNS 10%        |
| input20      | 113         | 40    | 0,95       | 4,69   | 4,56   | 4,59   | 5,02   | B&B            |
| input26      | 185         | 60    | 33,73      | 25,50  | 24,67  | 24,81  | 24,38  | LNS 75%        |
| input34      | 137         | 42    | 21,92      | 26,68  | 26,08  | 26,38  | 26,41  | B&B            |
| <b>Total</b> | 1,182       | 373   | <b>623</b> | 756    | 754    | 754    | 753    | <b>B&amp;B</b> |

Tabela 3 – Gap de otimalidade (%) para diferentes taxas de destruição. Configuração: ordenação crescente, tempo LNS = 30s, limite global = 400s.

| Instância    | Disciplinas | Profs | B&B  | 10%  | 25%  | 50%  | 75%  | Melhor        |
|--------------|-------------|-------|------|------|------|------|------|---------------|
| input2       | 79          | 24    | 0,00 | 0,00 | 0,00 | 0,00 | 0,00 | Empate        |
| input5       | 84          | 29    | 0,00 | 0,00 | 0,00 | 0,00 | 0,00 | Empate        |
| input6       | 113         | 31    | 0,00 | 0,00 | 0,00 | 0,00 | 0,00 | Empate        |
| input7       | 99          | 28    | 0,60 | 0,60 | 0,60 | 0,60 | 0,60 | Empate        |
| input9       | 133         | 41    | 0,00 | 0,00 | 0,00 | 0,00 | 0,00 | Empate        |
| input13      | 125         | 39    | 0,00 | 0,00 | 0,00 | 0,00 | 0,00 | Empate        |
| input19      | 114         | 39    | 0,00 | 0,00 | 0,00 | 0,00 | 0,00 | Empate        |
| input20      | 113         | 40    | 0,00 | 0,00 | 0,00 | 0,00 | 0,00 | Empate        |
| input26      | 185         | 60    | 0,00 | 0,00 | 0,00 | 0,00 | 0,00 | Empate        |
| input34      | 137         | 42    | 0,00 | 0,00 | 0,00 | 0,00 | 0,00 | Empate        |
| <b>Total</b> | 1.182       | 373   | 0,60 | 0,60 | 0,60 | 0,60 | 0,60 | <b>Empate</b> |

o critério de desempate utilizado foi a quantidade de nós restantes na árvore de Branch-and-Bound ao final da execução, métrica que reflete o progresso em direção à prova de otimalidade. A Tabela 4 revela que a configuração com 75% de destruição alcançou o menor total de nós restantes: **58.921 nós**, comparado a 66.230 (B&B puro), 62.628 (10%), 60.540 (25%) e 61.056 (50%). Todas as configurações obtiveram resultado idêntico em 9 das 10 instâncias (resolvidas até a otimalidade), mas na instância crítica input7, a taxa de 75% demonstrou maior capacidade de exploração e poda da árvore. A Figura 1 apresenta visualmente a comparação dos totais, evidenciando a superioridade da configuração de 75%.

**Conclusão Parcial.** A taxa de destruição de **75%** foi selecionada para as análises subsequentes, pois demonstrou melhor capacidade de redução da árvore de busca na instância difícil. Esse resultado indica que vizinhanças maiores permitem ao LNS realizar explorações mais agressivas e produtivas do espaço de soluções, reforçando a estratégia

Tabela 4 – Número de nós restantes na árvore de Branch-and-Bound para diferentes taxas de destruição. Configuração: ordenação crescente, tempo LNS = 30s, limite global = 400s.

| Instância    | Disciplinas  | Profs      | B&B           | 10%           | 25%           | 50%           | 75%           | Melhor         |
|--------------|--------------|------------|---------------|---------------|---------------|---------------|---------------|----------------|
| input2       | 79           | 24         | 0             | 0             | 0             | 0             | 0             | –              |
| input5       | 84           | 29         | 0             | 0             | 0             | 0             | 0             | –              |
| input6       | 113          | 31         | 0             | 0             | 0             | 0             | 0             | –              |
| input7       | 99           | 28         | 66.230        | 62.628        | 60.540        | 61.056        | <b>58.921</b> | <b>75%</b>     |
| input9       | 133          | 41         | 0             | 0             | 0             | 0             | 0             | –              |
| input13      | 125          | 39         | 0             | 0             | 0             | 0             | 0             | –              |
| input19      | 114          | 39         | 0             | 0             | 0             | 0             | 0             | –              |
| input20      | 113          | 40         | 0             | 0             | 0             | 0             | 0             | –              |
| input26      | 185          | 60         | 0             | 0             | 0             | 0             | 0             | –              |
| input34      | 137          | 42         | 0             | 0             | 0             | 0             | 0             | –              |
| <b>Total</b> | <b>1.182</b> | <b>373</b> | <b>66.230</b> | <b>62.628</b> | <b>60.540</b> | <b>61.056</b> | <b>58.921</b> | <b>LNS 75%</b> |




Figura 1 – Número total de nós restantes na árvore de Branch-and-Bound para diferentes taxas de destruição do LNS. A configuração de 75% apresentou o melhor desempenho com 58.921 nós restantes.

de intensificação adotada pela matheurística.

#### 4.2.2 Impacto do Sentido de Ordenação (Crescente vs. Decrescente)

Com a taxa de destruição fixada em 75%, investigou-se o impacto do sentido de ordenação dos candidatos pelo valor de `avgPreferenceWeight` ((3.2)). Conforme descrito no Capítulo 3, a ordenação crescente prioriza a liberação de professores mais versáteis (maior número de preferências declaradas), enquanto a decrescente prioriza professores mais especializados (menor número de preferências).

**Tempo de Execução.** A Tabela 5 revela desempenho temporal praticamente idêntico entre as duas estratégias: 1.803,48 segundos (crescente) versus 1.804,48 segundos (decrescente) no tempo total, com diferença de apenas 1 segundo. O B&B puro obteve o



menor tempo total com **1.792,24 segundos**. Das 10 instâncias testadas, quatro atingiram o limite de tempo em ambas as configurações (input4, input15, input17 e input33), e as demais apresentaram variações inferiores a 1 segundo. O tempo, portanto, não permitiu diferenciar as estratégias de ordenação.

Tabela 5 – Tempo de execução (segundos) comparando ordenação crescente e decrescente. Configuração: 75% de destruição, tempo LNS = 30s, limite global = 400s.

| Instância    | Disciplinas | Profs | B&B             | Crescente | Decrescente | Melhor         |
|--------------|-------------|-------|-----------------|-----------|-------------|----------------|
| input4       | 123         | 46    | 400,05          | 400,04    | 400,05      | Crescente      |
| input5       | 214         | 69    | 114,18          | 140,64    | 141,47      | Crescente      |
| input12      | 115         | 37    | 5,79            | 25,70     | 25,84       | Crescente      |
| input15      | 94          | 30    | 400,03          | 400,02    | 400,02      | Decrescente    |
| input16      | 89          | 28    | 3,07            | 0,72      | 0,72        | Decrescente    |
| input17      | 108         | 38    | 400,04          | 400,04    | 400,03      | Decrescente    |
| input20      | 104         | 37    | 0,90            | 4,40      | 4,32        | Decrescente    |
| input33      | 104         | 36    | 400,03          | 400,03    | 400,03      | Decrescente    |
| input37      | 152         | 53    | 68,00           | 31,61     | 31,62       | Crescente      |
| input38      | 62          | 22    | 0,16            | 0,28      | 0,28        | Decrescente    |
| <b>Total</b> | 1.165       | 396   | <b>1.792,24</b> | 1.803,48  | 1.804,48    | <b>B&amp;B</b> |

**Gap de Otimalidade.** Ambas as configurações mantiveram gap total idêntico de 1,62%, distribuído entre quatro instâncias não resolvidas de forma ótima (input4, input15, input17 e input33), com gaps individuais variando de 0,20% a 0,73% (ver Tabela 6). O empate no gap impediu, novamente, seu uso como critério de seleção.

Tabela 6 – Gap de otimalidade (%) comparando ordenação crescente e decrescente. Configuração: 75% de destruição, tempo LNS = 30s, limite global = 400s.

| Instância    | Disciplinas | Profs | B&B  | Crescente | Decrescente | Melhor        |
|--------------|-------------|-------|------|-----------|-------------|---------------|
| input4       | 123         | 46    | 0,20 | 0,20      | 0,20        | Empate        |
| input5       | 214         | 69    | 0,00 | 0,00      | 0,00        | Empate        |
| input12      | 115         | 37    | 0,00 | 0,00      | 0,00        | Empate        |
| input15      | 94          | 30    | 0,73 | 0,73      | 0,73        | Empate        |
| input16      | 89          | 28    | 0,00 | 0,00      | 0,00        | Empate        |
| input17      | 108         | 38    | 0,20 | 0,20      | 0,20        | Empate        |
| input20      | 104         | 37    | 0,00 | 0,00      | 0,00        | Empate        |
| input33      | 104         | 36    | 0,49 | 0,49      | 0,49        | Empate        |
| input37      | 152         | 53    | 0,00 | 0,00      | 0,00        | Empate        |
| input38      | 62          | 22    | 0,00 | 0,00      | 0,00        | Empate        |
| <b>Total</b> | 1.165       | 396   | 1,62 | 1,62      | 1,62        | <b>Empate</b> |

**Nós Restantes (*Nodes Left*).** A métrica de nós restantes revelou vantagem para a ordenação crescente. A Tabela 7 mostra que a configuração crescente resultou em **131.997 nós restantes** no total, enquanto a decrescente deixou 133.674 nós — uma redução de 1.677 nós (1,25%). A diferença se concentra em duas instâncias críticas:

input15 (61.546 vs. 62.452 nós) e input33 (46.243 vs. 47.063 nós). A Figura 2 apresenta a comparação visual dos totais.

Tabela 7 – Número de nós restantes comparando ordenação crescente e decrescente. Configuração: 75% de destruição, tempo LNS = 30s, limite global = 400s.

| Instância    | Disciplinas  | Profs      | B&B            | Crescente      | Decrescente    | Melhor           |
|--------------|--------------|------------|----------------|----------------|----------------|------------------|
| input4       | 123          | 46         | 19.797         | 19.541         | 19.507         | Decrescente      |
| input5       | 214          | 69         | 0              | 0              | 0              | –                |
| input12      | 115          | 37         | 0              | 0              | 0              | –                |
| input15      | 94           | 30         | 64.711         | 61.546         | 62.452         | Crescente        |
| input16      | 89           | 28         | 0              | 0              | 0              | –                |
| input17      | 108          | 38         | 4.673          | 4.667          | 4.652          | Decrescente      |
| input20      | 104          | 37         | 0              | 0              | 0              | –                |
| input33      | 104          | 36         | 50.279         | 46.243         | 47.063         | Crescente        |
| input37      | 152          | 53         | 0              | 0              | 0              | –                |
| input38      | 62           | 22         | 0              | 0              | 0              | –                |
| <b>Total</b> | <b>1.165</b> | <b>396</b> | <b>139.460</b> | <b>131.997</b> | <b>133.674</b> | <b>Crescente</b> |




Figura 2 – Comparação do número total de nós restantes entre ordenação crescente e decrescente. A ordenação crescente (priorizando professores versáteis) obteve melhor desempenho com 131.997 nós restantes.

**Interpretação.** A superioridade da ordenação **crescente** sugere que, para o PDD, priorizar a realocação de professores mais versáteis (generalistas) oferece maior flexibilidade para o sub-MIP encontrar rearranjos que melhorem a solução global. Professores generalistas possuem preferências por um maior número de disciplinas, o que amplia o espaço de busca do sub-MIP e facilita a satisfação simultânea de múltiplas restrições de carga horária. A ordenação crescente foi, portanto, adotada para as análises subsequentes.

### 4.2.3 Impacto do Tempo Máximo do LNS (10s, 50s, 100s e 200s)

Com os parâmetros de taxa de destruição (75%) e ordenação (crescente) definidos, investigou-se o impacto do limite de tempo do sub-MIP (`lns_time`). Foram testados quatro valores: 10s, 50s, 100s e 200s, mantendo o limite global de 400 segundos por instância.

**Tempo de Execução.** A Tabela 8 apresenta resultados contraintuitivos: embora se esperasse que limites maiores de LNS aumentassem o tempo total, observou-se comportamento não monotônico. O tempo total foi de 1.629,17s (B&B puro), 1.647,01s (10s), 1.313,60s (50s), **1.039,68s (100s)** e 1.090,00s (200s). Destaca-se a instância input15, em que as configurações de 100s e 200s resolveram o problema em  $\sim 77$ s, contra 400s nas demais. A configuração de 100s obteve o menor tempo total, porém a diferença para 200s (50,32s) foi pequena, não permitindo uma conclusão unívoca por este critério.

Tabela 8 – Tempo de execução (segundos) para diferentes limites de tempo do sub-MIP. Configuração: 75% de destruição, ordenação crescente, limite global = 400s.

| Inst.        | Disc. | Prof. | B&B      | 10s      | 50s      | 100s            | 200s     | Melhor      |
|--------------|-------|-------|----------|----------|----------|-----------------|----------|-------------|
| input6       | 79    | 24    | 1,19     | 2,40     | 2,14     | 2,15            | 2,14     | 200s        |
| input14      | 99    | 28    | 14,21    | 22,31    | 68,47    | 118,44          | 168,12   | B&B         |
| input15      | 94    | 30    | 400,03   | 400,02   | 400,02   | 76,31           | 77,09    | 100s        |
| input21      | 104   | 31    | 6,98     | 3,02     | 3,04     | 3,05            | 3,10     | 10s         |
| input22      | 133   | 41    | 400,05   | 400,04   | 400,04   | 400,04          | 400,04   | 10s         |
| input23      | 118   | 35    | 1,55     | 11,41    | 12,80    | 12,66           | 12,50    | 10s         |
| input27      | 125   | 39    | 4,93     | 7,45     | 7,34     | 7,33            | 7,31     | 200s        |
| input29      | 103   | 39    | 400,03   | 400,03   | 19,42    | 19,40           | 19,39    | 200s        |
| input33      | 104   | 36    | 400,03   | 400,03   | 400,03   | 400,03          | 400,03   | 200s        |
| input38      | 62    | 22    | 0,16     | 0,28     | 0,28     | 0,28            | 0,28     | 100s        |
| <b>Total</b> | 1,021 | 325   | 1.629,17 | 1.647,01 | 1.313,60 | <b>1.039,68</b> | 1.090,00 | <b>100s</b> |

Essa redução de tempo com limites maiores de LNS pode ser explicada pela capacidade de encontrar soluções de melhor qualidade mais cedo: uma incumbente mais forte permite podas mais agressivas na árvore de Branch-and-Bound, acelerando a convergência. Configurações com tempo insuficiente (10s) produzem melhorias marginais que não compensam o *overhead* da heurística.

**Gap de Otimalidade.** A Tabela 9 mostra que as configurações de 100s e 200s empataram com gap total de **0,72%**, substancialmente inferior ao obtido pelo B&B puro e pelo LNS com 10s (ambos com 1,73%). O destaque vai para a instância input15, resolvida até a otimalidade (gap 0,00%) apenas pelas configurações de 100s e 200s, e para a instância input33, cujo gap caiu de 0,49% (B&B puro) para 0,24% com 100s e 200s. Entretanto, o empate entre 100s e 200s impediu o uso do gap como critério final.

**Nós Restantes (*Nodes Left*).** A Tabela 10 foi o critério de desempate definitivo. O total de nós restantes foi: 135.986 (B&B puro), 144.674 (10s), 130.424 (50s), 51.935

Tabela 9 – Gap de otimalidade (%) para diferentes limites de tempo do sub-MIP. Configuração: 75% de destruição, ordenação crescente, limite global = 400s.

| Inst.        | Disc. | Prof. | B&B  | 10s  | 50s  | 100s        | 200s        | Melhor        |
|--------------|-------|-------|------|------|------|-------------|-------------|---------------|
| input6       | 79    | 24    | 0,00 | 0,00 | 0,00 | 0,00        | 0,00        | Empate        |
| input14      | 99    | 28    | 0,00 | 0,00 | 0,00 | 0,00        | 0,00        | Empate        |
| input15      | 94    | 30    | 0,73 | 0,73 | 0,73 | 0,00        | 0,00        | 100s          |
| input21      | 104   | 31    | 0,00 | 0,00 | 0,00 | 0,00        | 0,00        | Empate        |
| input22      | 133   | 41    | 0,32 | 0,32 | 0,32 | 0,48        | 0,48        | B&B           |
| input23      | 118   | 35    | 0,00 | 0,00 | 0,00 | 0,00        | 0,00        | Empate        |
| input27      | 125   | 39    | 0,00 | 0,00 | 0,00 | 0,00        | 0,00        | Empate        |
| input29      | 103   | 39    | 0,19 | 0,19 | 0,00 | 0,00        | 0,00        | 50s           |
| input33      | 104   | 36    | 0,49 | 0,49 | 0,49 | 0,24        | 0,24        | 100s          |
| input38      | 62    | 22    | 0,00 | 0,00 | 0,00 | 0,00        | 0,00        | Empate        |
| <b>Total</b> | 1.021 | 325   | 1,73 | 1,73 | 1,54 | <b>0,72</b> | <b>0,72</b> | <b>Empate</b> |

(100s) e **33.539 (200s)**. A configuração de 200s reduziu os nós em 75,3% em relação ao B&B puro e em 76,8% em relação ao LNS com 10s. As instâncias input15 e input29 foram resolvidas completamente (0 nós restantes) pelas configurações de 100s e 200s, enquanto permaneceram com dezenas de milhares de nós nas configurações inferiores. Na instância input33, a configuração de 200s deixou apenas 539 nós, contra 1.524 com 100s. A Figura 3 apresenta a comparação visual dos totais, evidenciando a clara superioridade do limite de 200s.

Tabela 10 – Número de nós restantes para diferentes limites de tempo do sub-MIP. Configuração: 75% de destruição, ordenação crescente, limite global = 400s.

| Inst.        | Disc. | Prof. | B&B     | 10s     | 50s     | 100s   | 200s          | Melhor      |
|--------------|-------|-------|---------|---------|---------|--------|---------------|-------------|
| input6       | 79    | 24    | 0       | 0       | 0       | 0      | 0             | –           |
| input14      | 99    | 28    | 0       | 0       | 0       | 0      | 0             | –           |
| input15      | 94    | 30    | 54.355  | 63.056  | 59.819  | 0      | 0             | 100s        |
| input21      | 104   | 31    | 0       | 0       | 0       | 0      | 0             | –           |
| input22      | 133   | 41    | 21.528  | 29.161  | 25.100  | 50.411 | 33.000        | 50s         |
| input23      | 118   | 35    | 0       | 0       | 0       | 0      | 0             | –           |
| input27      | 125   | 39    | 0       | 0       | 0       | 0      | 0             | –           |
| input29      | 103   | 39    | 12.643  | 4.347   | 0       | 0      | 0             | 50s         |
| input33      | 104   | 36    | 47.460  | 48.110  | 45.505  | 1.524  | 539           | 200s        |
| input38      | 62    | 22    | 0       | 0       | 0       | 0      | 0             | –           |
| <b>Total</b> | 1.021 | 325   | 135.986 | 144.674 | 130.424 | 51.935 | <b>33.539</b> | <b>200s</b> |

**Conclusão Parcial.** O limite de **200 segundos** demonstrou o melhor desempenho global, reduzindo drasticamente a árvore de busca e resolvendo instâncias que outras configurações não conseguiram. Para problemas combinatórios como o PDD, investir mais tempo em cada chamada do LNS é compensado por soluções de maior qualidade, que aceleram a convergência do Branch-and-Bound. O *trade-off* entre intensidade (tempo por chamada) e frequência (número de chamadas) favorece claramente a intensidade para este




Figura 3 – Impacto do limite de tempo do sub-MIP no número de nós restantes. A configuração de 200s demonstrou o melhor desempenho com 33.539 nós, representando uma redução de 75,3% em relação ao B&B puro.

problema.

#### 4.2.4 Resumo da Configuração Seleccionada

A Tabela 11 resume os parâmetros seleccionados ao longo da análise incremental.

Tabela 11 – Configuração final da heurística LNS seleccionada pela análise incremental.

| Parâmetro                                    | Valores Testados       | Seleccionado | Critério Decisivo |
|----------------------------------------------|------------------------|--------------|-------------------|
| Taxa de destruição ( <code>lns_perc</code> ) | 10%, 25%, 50%, 75%     | 75%          | Nós restantes     |
| Ordenação ( <code>lns_order</code> )         | Crescente, Decrescente | Crescente    | Nós restantes     |
| Tempo do sub-MIP ( <code>lns_time</code> )   | 10s, 50s, 100s, 200s   | 200s         | Nós restantes     |

Nota-se que, em todas as etapas, o tempo de execução não apresentou diferenças significativas entre as configurações LNS e o gap de otimalidade resultou em empate, sendo a métrica de nós restantes o critério de desempate definitivo. Esse padrão sugere que, para as instâncias avaliadas, o LNS atua predominantemente como acelerador da prova de otimalidade, reduzindo o esforço do Branch-and-Bound por meio de incumbentes de melhor qualidade.

### 4.3 Comparativo de Desempenho: LNS, GRASP e Modelo Exato

Com os parâmetros da LNS calibrados (75% de destruição, ordenação crescente e tempo de sub-MIP de 200s), realizou-se um comparativo final entre quatro configurações: (i) **B&B puro** (sem heurísticas primais customizadas), (ii) **LNS** (apenas a heurística LNS

proposta), (iii) **GRASP** (apenas a heurística GRASP, com `max_iter=1`,  $\alpha = 0,8$  e sem busca local (??)) e (iv) **GRASP|LNS** (ambas as heurísticas ativadas simultaneamente). As mesmas 10 instâncias foram utilizadas em todas as configurações.

### 4.3.1 Análise do Tempo de Execução

A Tabela 12 apresenta os tempos de execução para cada configuração. O **LNS** obteve o menor tempo total: **230,05 segundos**, representando uma redução de 69,1% em relação ao B&B puro (744,13s), de 82,5% em relação ao GRASP (1.314,27s) e de 60,9% em relação ao GRASP|LNS (587,94s).

Tabela 12 – Tempo de execução (segundos) comparando B&B puro, LNS, GRASP e GRASP|LNS. Configuração LNS: 75% destruição, crescente, 200s. Configuração GRASP: `max_iter=1`,  $\alpha=0.8$ , `local_search=0`.

| Instância    | Disciplinas | Profs | B&B    | LNS           | GRASP    | GRASP LNS | Melhor     |
|--------------|-------------|-------|--------|---------------|----------|-----------|------------|
| input5       | 214         | 69    | 112,63 | 54,46         | 400,12   | 83,09     | LNS        |
| input11      | 100         | 31    | 1,54   | 2,59          | 3,90     | 0,83      | GRASP LNS  |
| input15      | 94          | 30    | 400,03 | 79,90         | 400,02   | 400,02    | LNS        |
| input16      | 89          | 28    | 3,07   | 0,75          | 8,38     | 0,36      | GRASP LNS  |
| input19      | 95          | 29    | 2,03   | 1,45          | 5,74     | 2,73      | LNS        |
| input21      | 104         | 31    | 5,93   | 3,16          | 13,45    | 4,42      | LNS        |
| input25      | 107         | 34    | 15,63  | 9,27          | 37,64    | 9,54      | LNS        |
| input30      | 109         | 36    | 3,21   | 1,36          | 7,94     | 2,36      | LNS        |
| input35      | 169         | 53    | 186,72 | 63,27         | 400,07   | 71,20     | LNS        |
| input42      | 142         | 35    | 6,91   | 8,18          | 20,19    | 13,39     | B&B        |
| <b>Total</b> | 1.329       | 409   | 744,13 | <b>230,05</b> | 1.314,27 | 587,94    | <b>LNS</b> |

Dentre as 10 instâncias, o LNS foi o mais rápido em 7 delas, com destaque para a instância input15: enquanto o B&B puro e o GRASP atingiram o limite de 400s, o LNS resolveu a instância em 79,90s. A instância input35, com 169 disciplinas e 53 professores, exemplifica o impacto da heurística: o LNS concluiu em 63,27s contra 186,72s do B&B puro e 400,07s do GRASP. A Figura 4 ilustra a comparação dos tempos totais.

O GRASP apresentou o pior desempenho temporal, atingindo o limite de tempo em 3 das 10 instâncias (input5, input15 e input35). Esse resultado sugere que a heurística construtiva do GRASP, embora forneça soluções iniciais viáveis rapidamente, não contribui de forma eficaz para a redução da árvore de busca do Branch-and-Bound.

### 4.3.2 Análise do Gap de Otimalidade

A Tabela 13 apresenta o gap de otimalidade para cada configuração. O **LNS** atingiu **gap total de 0,00%**, provando a otimalidade de todas as 10 soluções encontradas. O B&B puro obteve 0,73% (devido à instância input15 não resolvida), a GRASP|LNS obteve 0,24% (input15 com gap residual) e o GRASP apresentou o pior resultado com




Figura 4 – Tempo total de execução (segundos) para cada configuração. O LNS obteve o menor tempo total (230,05s), representando uma redução de 69,1% em relação ao B&B puro e de 82,5% em relação ao GRASP.

3,46% de gap total, com três instâncias sem solução ótima comprovada (input5 com 1,01%, input15 com 0,24% e input35 com 2,21%). A Figura 5 apresenta a comparação visual.

Tabela 13 – Gap de otimalidade (%) comparando B&B puro, LNS, GRASP e GRASP|LNS. Configuração LNS: 75% destruição, crescente, 200s. Configuração GRASP: max\_iter=1, alpha=0.8, local\_search=0.

| Instância    | Disciplinas | Profs | B&B  | LNS         | GRASP | GRASP LNS | Melhor     |
|--------------|-------------|-------|------|-------------|-------|-----------|------------|
| input5       | 214         | 69    | 0,00 | 0,00        | 1,01  | 0,00      | LNS        |
| input11      | 100         | 31    | 0,00 | 0,00        | 0,00  | 0,00      | LNS        |
| input15      | 94          | 30    | 0,73 | 0,00        | 0,24  | 0,24      | LNS        |
| input16      | 89          | 28    | 0,00 | 0,00        | 0,00  | 0,00      | LNS        |
| input19      | 95          | 29    | 0,00 | 0,00        | 0,00  | 0,00      | LNS        |
| input21      | 104         | 31    | 0,00 | 0,00        | 0,00  | 0,00      | LNS        |
| input25      | 107         | 34    | 0,00 | 0,00        | 0,00  | 0,00      | LNS        |
| input30      | 109         | 36    | 0,00 | 0,00        | 0,00  | 0,00      | LNS        |
| input35      | 169         | 53    | 0,00 | 0,00        | 2,21  | 0,00      | LNS        |
| input42      | 142         | 35    | 0,00 | 0,00        | 0,00  | 0,00      | LNS        |
| <b>Total</b> | 1.223       | 376   | 0,73 | <b>0,00</b> | 3,46  | 0,24      | <b>LNS</b> |

A superioridade do LNS no gap é particularmente expressiva: enquanto o B&B puro não conseguiu provar a otimalidade da instância input15 em 400s, o LNS resolveu-a completamente. O GRASP, por sua vez, não apenas falhou em provar otimalidade, como também obteve soluções de pior qualidade em duas instâncias (input5 e input35), conforme indicado pelos gaps de 1,01% e 2,21%.




Figura 5 – Gap de otimalidade total (%) para cada configuração. O LNS atingiu gap zero, provando a otimalidade de todas as soluções encontradas.

### 4.3.3 Análise dos Nós Restantes

A Tabela 14 evidencia a vantagem competitiva do LNS em relação aos demais. O **LNS alcançou 0 nós restantes** no total, indicando que todas as instâncias foram resolvidas até a otimalidade dentro do limite de tempo. O B&B puro deixou 64.364 nós (todos da instância input15), o GRASP deixou 36.303 nós (distribuídos entre input5, input15 e input35) e a GRASP|LNS deixou 2.324 nós (apenas input15). A Figura 6 apresenta a comparação.

Tabela 14 – Número de nós restantes comparando B&B puro, LNS, GRASP e GRASP|LNS. Configuração LNS: 75% destruição, crescente, 200s. Configuração GRASP: max\_iter=1, alpha=0.8, local\_search=0.

| Instância    | Disciplinas | Profs | B&B    | LNS      | GRASP  | GRASP LNS | Melhor     |
|--------------|-------------|-------|--------|----------|--------|-----------|------------|
| input5       | 214         | 69    | 0      | 0        | 8.037  | 0         | LNS        |
| input11      | 100         | 31    | 0      | 0        | 0      | 0         | LNS        |
| input15      | 94          | 30    | 64.364 | 0        | 7.526  | 2.324     | LNS        |
| input16      | 89          | 28    | 0      | 0        | 0      | 0         | LNS        |
| input19      | 95          | 29    | 0      | 0        | 0      | 0         | LNS        |
| input21      | 104         | 31    | 0      | 0        | 0      | 0         | LNS        |
| input25      | 107         | 34    | 0      | 0        | 0      | 0         | LNS        |
| input30      | 109         | 36    | 0      | 0        | 0      | 0         | LNS        |
| input35      | 169         | 53    | 0      | 0        | 20.740 | 0         | LNS        |
| input42      | 142         | 35    | 0      | 0        | 0      | 0         | LNS        |
| <b>Total</b> | 1.223       | 376   | 64.364 | <b>0</b> | 36.303 | 2.324     | <b>LNS</b> |

### 4.3.4 Discussão dos Resultados

Os resultados do comparativo evidenciam que a matheurística LNS proposta supera consistentemente tanto o Branch-and-Bound puro quanto o GRASP em todas as






Figura 6 – Total de nós restantes na árvore de Branch-and-Bound para cada configuração. O LNS alcançou 0 nós restantes, resolvendo todas as instâncias até a otimalidade.

métricas avaliadas. A Tabela 15 sintetiza os principais indicadores.

Tabela 15 – Resumo comparativo das quatro configurações avaliadas.

| Métrica               | B&B puro | LNS           | GRASP    | GRASP LNS |
|-----------------------|----------|---------------|----------|-----------|
| Tempo total (s)       | 744,13   | <b>230,05</b> | 1.314,27 | 587,94    |
| Gap total (%)         | 0,73     | <b>0,00</b>   | 3,46     | 0,24      |
| Nós restantes (total) | 64.364   | <b>0</b>      | 36.303   | 2.324     |
| Instâncias ótimas     | 9/10     | <b>10/10</b>  | 7/10     | 9/10      |

A análise revela três observações principais:

1. **O LNS é o método mais eficaz.** Com a configuração calibrada (75% de destruição, ordenação crescente, 200s de sub-MIP), o LNS resolveu todas as instâncias até a otimalidade, com tempo total 3,2 vezes menor que o B&B puro e 5,7 vezes menor que o GRASP (230,05s contra 744,13s e 1.314,27s, respectivamente). A estratégia de intensificação via sub-MIP gera incumbentes de alta qualidade que viabilizam podas mais eficientes na árvore de busca.
2. **A combinação GRASP|LNS não supera o LNS isolado.** Embora a GRASP|LNS tenha apresentado desempenho superior ao B&B puro e ao GRASP, o *overhead* da heurística construtiva GRASP não trouxe benefícios adicionais quando o LNS já estava ativo. Isso sugere que o LNS é capaz de encontrar incumbentes de qualidade suficiente sem a necessidade de uma solução inicial heurística dedicada.
3. **O GRASP isolado apresenta limitações para o PDD.** O GRASP atingiu o limite de tempo em 30% das instâncias e não conseguiu provar a otimalidade em

3 delas. A heurística construtiva, embora gere soluções viáveis rapidamente, não contribui de forma significativa para a redução do espaço de busca, e o *overhead* computacional de sua execução a cada nó penaliza o desempenho global.

## 5 Conclusão

Este trabalho propôs, implementou e avaliou uma matheurística baseada em Large Neighborhood Search (LNS) com reotimização por sub-MIP, em um esquema do tipo *fix-and-optimize*, integrada como heurística primal ao solver SCIP 7.0, para o Problema da Distribuição de Disciplinas (PDD). O problema foi modelado como um programa linear inteiro binário, cuja função objetivo maximiza a qualidade da atribuição de disciplinas a professores, respeitando restrições de carga horária mínima anual e máxima semestral.

A calibração dos parâmetros internos da LNS foi conduzida via abordagem *one-factor-at-a-time*, avaliando três parâmetros: taxa de destruição, sentido de ordenação dos candidatos e tempo máximo do sub-MIP. Em todas as etapas, a métrica de nós restantes na árvore de Branch-and-Bound foi o critério decisivo, uma vez que tempo de execução e gap de otimalidade não apresentaram diferenças significativas entre as configurações testadas. A configuração final selecionada — 75% de destruição, ordenação crescente por `avgPreferenceWeight` e 200 segundos de sub-MIP — demonstrou que vizinhanças maiores e investimentos mais longos em cada chamada do LNS são compensados por incumbentes de melhor qualidade, que aceleram a convergência do Branch-and-Bound.

No comparativo final entre quatro abordagens (B&B puro, LNS, GRASP e GRASP|LNS), a matheurística LNS superou todas as demais em todas as métricas avaliadas: resolveu as 10 instâncias até a otimalidade (gap 0,00%), com tempo total de 230,05 segundos — 3,2 vezes menor que o B&B puro e 5,7 vezes menor que o GRASP. A combinação GRASP|LNS não trouxe ganhos adicionais frente ao LNS isolado, indicando que a heurística LNS é capaz de gerar incumbentes de qualidade suficiente sem necessidade de uma solução inicial construtiva dedicada.

Os resultados confirmam que a integração de uma matheurística LNS ao Branch-and-Bound é uma estratégia eficaz para o PDD, cumprindo todos os objetivos propostos: modelagem do problema como PLI, implementação de uma heurística LNS do tipo *fix-and-optimize* no SCIP, análise do impacto dos parâmetros internos e comparação com abordagens alternativas.

### 5.1 Limitações

As principais limitações deste trabalho são:

1. A calibração *one-factor-at-a-time* ajusta os parâmetros de forma sequencial, sem explorar possíveis interações entre eles. Uma análise fatorial completa ou métodos de *design of experiments* poderiam revelar combinações mais eficientes.

2. Os experimentos utilizaram exclusivamente instâncias sintéticas geradas aleatoriamente. A validação com dados reais de instituições de ensino fortaleceria a generalização dos resultados.
3. A configuração do GRASP utilizada na comparação (`max_iter=1`, sem busca local) representa uma versão simplificada da heurística. Uma parametrização mais elaborada poderia alterar o desempenho relativo.
4. O limite de tempo global fixo de 400 segundos por instância não permite avaliar o comportamento das abordagens sob restrições temporais mais rígidas ou mais flexíveis.

## 5.2 Trabalhos Futuros

Como direções para trabalhos futuros, destacam-se:

1. Investigar estratégias adaptativas para os parâmetros do LNS, ajustando dinamicamente a taxa de destruição e o tempo do sub-MIP com base no progresso da busca.
2. Avaliar a metaheurística em instâncias de maior porte e com dados reais de instituições de ensino, incluindo restrições adicionais como preferências de horário e indisponibilidades.
3. Explorar critérios alternativos de seleção de candidatos à destruição, como métricas baseadas na contribuição marginal de cada atribuição à função objetivo.
4. Comparar o desempenho com solvers comerciais (Gurobi, CPLEX) e com outras metaheurísticas, como Busca Tabu e Algoritmos Genéticos.
5. Estender o modelo para variantes multiobjetivo do PDD, considerando simultaneamente qualidade da atribuição, equilíbrio de carga entre professores e custos operacionais.